



**Instituto Tecnológico Superior de
Ciudad Constitución.**

**INGENIERÍA EN SISTEMAS
COMPUTACIONALES.**

Ciencia de datos

“Tratamiento Datos Parte1”

Instructor: Isaac Felipe Garcia Lopez

Grupo: 8SM

Alumno: Luis Manuel Muñoz Lizarraga

Fecha de entrega: 24 - 04 - 2026

Cd. Constitución, B.C.S.

Introducción

El presente trabajo tiene como objetivo analizar la calidad de los datos del archivo `pipol_datos.csv`, identificando problemas relacionados con la integridad de la información, como valores nulos, valores atípicos (outliers), valores negativos y errores ortográficos en datos categoricos.

Posteriormente, se desarrollaron funciones en Python utilizando la librería Pandas para corregir estos problemas, mejorar la consistencia del dataset y facilitar futuros análisis de datos más confiables.

Análisis de Integridad de los Datos

Durante la revisión inicial del archivo CSV se detectaron diversos problemas que afectan la calidad de los datos.

Hallazgos encontrados

1. Valores nulos

Se encontraron valores faltantes en varias columnas importantes:

- sex → 10,000 valores nulos
- city → 10,000 valores nulos
- education → 22,437 valores nulos

Estos valores faltantes afectan el análisis y deben ser tratados adecuadamente.

2. Valores atípicos (Outliers)

En la columna age se detectaron edades demasiado elevadas, como:

- 188 años
- 193 años
- 199 años

Utilizando el método Z-score se identificaron:

2362 registros con valores atípicos

Estas edades no son realistas y afectan el análisis estadístico.

3. Valores negativos

Se detectaron valores negativos en:

- income (ingresos)
- children (cantidad de hijos)

Ejemplos:

- income = -1886
- children = -5

Estos valores no son válidos dentro del contexto del problema.

4. Errores ortográficos y de formato

En la columna education se encontraron inconsistencias como:

- PhD
- pHd
- Master
- mastre
- Bachelor
- Bachelors

Esto genera categorías duplicadas y errores en el análisis.

Soluciones Implementadas

Para corregir los problemas detectados se desarrollaron funciones en Python.

1. Eliminación de valores negativos

Se reemplazaron los valores negativos por 0 utilizando una función con `apply()` y `lambda`.

Esto se aplicó en:

- income
- Children

2. Corrección de valores nulos

Se realizó lo siguiente:

- En sex, los valores nulos fueron reemplazados por "Unknown"
- En age, si existieran valores nulos, se reemplazarían por el promedio

Esto mejora la completitud de los datos.

3. Detección de outliers

Se utilizó el método estadístico Z-score, que permite identificar valores extremos alejados de la media.

Esto ayudó a localizar edades fuera de rango realista.

4. Normalización de texto

Se transformaron los textos a minúsculas para evitar duplicados por diferencias de escritura.

Ejemplo:

- PhD → phd
- F → f
- M → m

Esto mejora la consistencia de los datos categóricos.

Código de las Funciones

Función para eliminar negativos

```
# Eliminar negativos
def eliminar_negativos(df, columnas):
    for col in columnas:
        df[col] = df[col].apply(lambda x: 0 if x < 0 else x)
    return df
```

Función para rellenar nulos

```
# Rellenar nulos
def rellenar_nulos(df):
    df["sex"] = df["sex"].fillna("Unknown")
    df["age"] = df["age"].fillna(df["age"].mean())
    return df
```

Función para detectar outliers

```
# Detectar outliers con Z-score
def detectar_outliers(df, columna):
    media = df[columna].mean()
    std = df[columna].std()
    z_scores = (df[columna] - media) / std
    return df[abs(z_scores) > 3]
```

Función para corregir texto

```
# Corregir texto
def corregir_texto(df):
    df["education"] = df["education"].str.lower()
    df["sex"] = df["sex"].str.lower()
    return df
```

Resultados Obtenidos

Después de aplicar las funciones de limpieza se obtuvo lo siguiente:

- Los valores negativos fueron reemplazados por 0
- Los valores nulos en sex fueron corregidos
- Se detectaron 2362 registros con edades atípicas
- Se redujeron errores en los datos categóricos
- Se mejoró significativamente la calidad general del dataset

Ejemplo de transformación:

Antes:

income = -1886

children = -5

sex = NaN

education = PhD

Después:

income = 0

children = 0

sex = unknown

education = phd

Esto demuestra que las funciones implementadas cumplieron correctamente su propósito.

Conclusión

La limpieza y tratamiento de datos es una etapa fundamental en cualquier proceso de análisis de información.

En este trabajo se logró identificar problemas importantes en el archivo pipol_datos.csv, como valores nulos, outliers, errores ortográficos y datos inválidos.

Mediante el uso de funciones en Python y la librería Pandas fue posible automatizar la corrección de estos errores, mejorando la integridad, consistencia y confiabilidad del dataset.

Esto permite que futuros análisis sean más precisos y útiles para la toma de decisiones.